

**Министерство науки и высшего образования
Российской Федерации**

**Федеральное государственное автономное
образовательное учреждение высшего образования
«Национальный исследовательский университет
ИТМО»**



**Факультет информационных технологий и
программирования**

Отчет для кейс-чемпионата

Тренды вопросов по тегам на Stack Overflow

Выполнили студенты групп № M3106, № M3107

Цыканова Ксения Александровна,
Акопян Мариам Карапетовна,
Зайцева Анна Дмитриевна,
Дуля Николай Сергеевич,
Кошкина Мария Вячеславовна

Санкт-Петербург
2026

Цель работы

Оценить интерес к технологиям на основе частоты новых вопросов, сравнить теги `sql`, `postgresql`, `mysql`, `sqlite`.

Задачи

- 1) Сбор данных - определение метрик, составление структуры `csv` и парсинг данных
- 2) Подготовка данных - распределение данных по таблицам, очистка от дубликатов и ошибок
- 3) Анализ - проведение расчётов заполнения таблиц и составление отчёта
- 4) Визуализация анализа - составление необходимых графиков и полного дашборда с помощью Yandex Datalens
- 5) Отчет и презентация - оформление репозитория, отчёта и презентация проекта

Ход работы

- 1) Сбор данных.

На первом этапе были выбраны основные метрики: **`sql`, `postgresql`, `mysql`, `sqlite`**. Далее была подготовлена структура данных для выгрузки в CSV-формате: выбраны поля (дата/время, тег, количество вопросов, информация о стране пользователя и тд.). После был выполнен парсинг данных и сохранение результатов в исходные CSV-таблицы.

- 2) Подготовка данных.

На этапе подготовки данные были приведены к корректному виду для дальнейшего анализа и визуализации. Были выполнены следующие действия:

- данные распределены по логическим таблицам;
- выполнена очистка от возможных дубликатов записей;
- исключены некорректные данные.

- 3) Анализ.

После подготовки данных был выполнен расчёт показателей, позволяющих сравнить теги между собой. На основе этих расчётов были заполнены итоговые аналитические таблицы (например, `table_timeseries_ma7`, `table_tag_stats` и др.), и сформированы выводы по каждому пункту диагностики.

- 4) Визуализация анализа.

Для представления результатов были построены диаграммы в Yandex DataLens:

- график изменения интереса по времени (линейный график MA7);
- сравнение тегов по среднему уровню активности;
- и другие.

После построения всех визуализаций они были объединены в единый дэшборд.

5) Отчет и презентация.

На финальном этапе была выполнена подготовка итоговых материалов: составление презентации и отчета, выгрузка материалов в репозиторий.

Результаты анализа (Ответы на вопросы)

Есть ли рост/спад интереса по времени?




Рис. 1 Диаграмма анализа роста интереса по времени

(сравнение среднего MA7 в начале периода vs в конце периода)

postgresql: MA7 ↓ с 3,571 до 3,286 (Δ -0,285) → слабый спад

sql: MA7 ↓ с 3,286 до 1,857 (Δ -1,429) → выраженный спад

mysql: MA7 ↓ с 1,429 до 0,857 (Δ -0,572) → умеренный спад

sqlite: MA7 ↓ с 0,571 до 0,286 (Δ -0,285) → слабый спад

Прогноз:

Postgresql:

ожидается сохранение слабого спада; среднее число вопросов будет колебаться чуть ниже текущего уровня MA7; возможны краткосрочные пики, но без резких спадов.

Sql: ожидается продолжение снижения или стагнация; возможны отдельные пиковые дни, но они не меняют общего направления; средний уровень останется ниже значений начала периода.

Mysql: интерес останется на низком уровне; вероятно чередование нулевых и единичных дней; системного роста не ожидается.

Sqlite: сохранение низкой и нерегулярной активности; рост маловероятен без внешних изменений.

Как растёт число вопросов в течение дня?




Рис. 2 Диаграмма пиков и провалов по часам

Ключевые точки накопления (час, к которому набирается доля суточного объёма):

Mysql: 50% к 12:00, 80% к 16:00

Postgresql: 50% к 13:00, 80% к 18:00

Sql: 50% к 14:00, 80% к 19:00

Sqlite: 50% к 13:00, 80% к 19:00

Основной объём вопросов накапливается во второй половине дня. Sql и postgresql характеризуются более поздним набором активности по сравнению с mysql.

Насколько сезонны вопросы (дни недели)?



Рис. 3 Таблица heatmap




Рис. 4 Диаграмма-диагностика «как растет в течение дня» (накопление)

В выходные общая интенсивность ниже; пики более сглажены. Для **sql** и **postgresql** будничной профиль заметно отличается от выходного; для **mysql** и **sqlite** различия слабее из-за низкой общей активности.

Вывод: Суточный профиль активности различается между буднями и выходными, особенно для тегов с высоким уровнем интереса.

Какие теги наиболее/наименее популярны?




Рис. 5 Диаграмма-диагностика уровня интереса по среднему числу вопросов в день

postgresql (2.57) и **sql** (2.53) имеют самый высокий уровень интереса, так как широко используются в самых разных проектах, привлекают пользователей разного уровня и регулярно порождают сложные вопросы, требующие обсуждения. Для **postgresql** дополнительно влияет активное развитие экосистемы.

mysql (0.80) показывает низкий уровень интереса, что может быть связано с высокой зрелостью технологии, наличием большого объема готовых решений и меньшим числом новых или нестандартных задач.

sqlite (0.52) имеет самый низкий уровень интереса из-за узкой области применения, относительной простоты и редкого использования в сложных архитектурных сценариях, где обычно возникает наибольшее число вопросов.

Из какого региона больше всего вопросов?




Рис. 6 Количество вопросов по странам за последние полгода

По статистике наибольшее число пользователей Stack Overflow из США, Индии, Великобритании, Германии, России. Диаграмма отображает соответствие статистическим данным, однако пользователей из России может быть меньше за счет существования аналогичного русскоязычного ресурса. Также столь малое число запросов за полгода обусловлено тем, что не все пользователи публично указывают страну.

Вывод

В ходе работы был проведён анализ динамики интереса к технологиям **sql**, **postgresql**, **mysql**, **sqlite** на основе частоты новых вопросов на Stack Overflow за выбранный период. Для выявления тренда использовалось скользящее среднее МА7, а для сравнения тегов между собой — сводные статистические показатели (среднее значение, минимум/максимум и тп.).

Дополнительно было выявлено наличие аномалий и всплесков в активности всех тегов. Для **mysql** и **sqlite** аномальный характер данных в основном связан с большим числом дней без активности, тогда как для **sql** и

postgresql аномалии проявляются как внутри активных дней (значительные отклонения от среднего), так и за счёт пиков.